

Проектное задание по программе Промпт-инжиниринг и оптимизация стоимости LLM

Описание проекта

В рамках итоговой работы необходимо подготовить индивидуальный проект: сквозной LLM-пайплайн на GigaChat, который отвечает на набор вопросов по заданной базе знаний и который вы оптимизируете по стоимости (токенам) при удержании качества. Проект должен:

- принимать вопросы пользователя и отвечать по предоставленной базе знаний;
- использовать поиск по базе знаний (семантический и лексический) и вызов инструментов (function calling);
- возвращать ответы в фиксированном структурированном формате;
- замерять качество ответов и стоимость (токены, удельная стоимость результата) на золотом наборе;
- с помощью приемов промпт-инжиниринга снижать потребление токенов без потери качества, а эффект подтверждать количественно (замер «до / после»).

В ходе 8 практико-ориентированных занятий вы последовательно изучите все этапы создания такого пайплайна: работу с метриками качества и стоимостью обращения к модели, эмбединги и RAG, систему оценки LLM, агентные инструменты и оптимизацию промптов.

Что должно быть в проекте

Проект должен удовлетворять 6 обязательным критериям. Критерии сформулированы так, чтобы для их выполнения требовались знания со всех 8 занятий.

#	Критерии (обязательные)	Занятие
1	Реализован сквозной RAG-пайплайн на GigaChat над предоставленной базой знаний (индексация, поиск, генерация ответа)	1–3
2	Пайплайн использует минимум 2 инструмента поиска	8

#	Критерии (обязательные)	Занятие
	через function calling	
3	Ответы модели возвращаются в фиксированном структурированном формате	1
4	Применены приёмы оптимизации промптов и токенов: стоимость снижена при удержании качества, эффект обоснован количественно	5-7
5	Собран золотой набор и проведен воспроизводимый замер: метрики качества и стоимость (токены, удельная стоимость результата); приложен отчёт	4-6
6	После построения baseline проведены дополнительные эксперименты (продвинутые техники рассуждения, методы сокращения токенов, агенты) и проанализированы с помощью оценочного контура.	3-7-8

Данные для проекта

<https://drive.google.com/drive/folders/tw-laxxK-ikQrohziOTHX7ALhZO0DuVmm>

Формат презентации результата

- Отдельная папка со всеми необходимыми скриптами / колабом.*
- Скринкаст (запись экрана с комментариями автора, до 10 минут) с демонстрацией работы пайплайна и результатов оптимизации в разных сценариях.
- Код понятный и читаемый, функции и классы снабжены docstring.

* О работе с репозиторием, куда нужно сдать проект, рассказано ниже.

Консультации

3 сентября и 5 сентября в 18:00 состоятся две консультации в формате вебинара по вопросам проектной работы. Участники смогут задать любые вопросы, связанные с выполнением и подготовкой проекта.

Дедлайны и ключевые даты

- **27–28 августа** – проведение занятий.
- **3 сентября (18:00)** – консультация по проекту.
- **5 сентября (18:00)** – консультация по проекту.
- **8 сентября** – финальный дедлайн сдачи проекта.

Сроки проверки проектов

Срок проверки присланных проектов – 3 дня. Оценка выставляется по системе зачёт/незачёт; слушателю направляется развернутая обратная связь. При необходимости проект отправляется на доработку.

Вопросы по проектной деятельности

- Преподавателю во время проведения интенсива.
- Преподавателю во время консультаций по проекту.
- В общей Telegram/МАКС группе.
- Куратору группы через личные сообщения.

Где сдавать. Работа с репозиторием

Перейдите по [ссылке](https://git.standard-data.ru) (<https://git.standard-data.ru>) и авторизуйтесь под своими учётными данными (**высланные куратором логин и пароль**). В разделе групп <https://git.standard-data.ru/dashboard/groups> вас уже ждет ваша папка для сдачи проекта!

НЕ создавайте папку проекта самостоятельно! Преподаватели не увидят ее и не смогут проверить ваш проект.

Проблемы и вопросы

При любых затруднениях с доступом к GitLab или другими организационными вопросами обращайтесь к куратору группы через личные сообщения.